Геймификация повышает удержание, но не во всех классах

Решение по результатам трёхнедельного A/B-теста · VK Education

RETENTION D7

+5,26 п.п. | 72,71% → 77,96%

RETENTION D14

+7,46 п.п. | 28,76% → 36,23%

HOMEWORK CONVERSION

+1,20 п.п. | 97,63% → 98,83%

РЕШЕНИЕ - ДОРАБОТАТЬ ПЕРЕД МАССОВЫМ ЗАПУСКОМ

Общий эффект положительный и статистически значимый, но у 10-11 классов оценки эффекта отрицательны.

Что проверяли

Система достижений за решение задач: A - без механики, B - с геймификацией.

Масштаб

5 992 ученика после очистки: A = 2 997, B = 2 995; эксперимент - 3 недели.

Данные и продуктовые метрики

Контроль качества эксперимента → расчёт конверсии и удержания

Проверка данных

8 пользователей состояли в обеих группах - исключены.

2 точных дубликата событий удалены.

SRM: p = 0,979 (при 50/50).

Воронка событий

Login → Homework started → Homework completed

Конверсия = доля пользователей, завершивших ≥1 задание; не весь курс.

Метрика	Контроль A	Тест B	B − A
Retention D7	72,71%	77,96%	+5,26 п.п.
Retention D14	28,76%	36,23%	+7,46 п.п.
Завершили ≥1 ДЗ	97,63%	98,83%	+1,20 п.п.

Интерпретация

Метрики рассчитаны на уровне уникального пользователя; «завершение курса» по логам недоступно.

Статистическая проверка подтверждает общий эффект

Двусторонний z-тест долей · 95% доверительные интервалы · Holm для трёх проверок

Метрика	Эффект B − A	95% ДИ, п.п.	p после Holm
Retention D7	+5,26 п.п.	[+3,08; +7,43]	0,00000471
Retention D14	+7,46 п.п.	[+5,10; +9,82]	$2{,}06 \times 10^{-9}$
Homework conversion	+1,20 п.п.	[+0,54; +1,89]	0,000424

Вывод

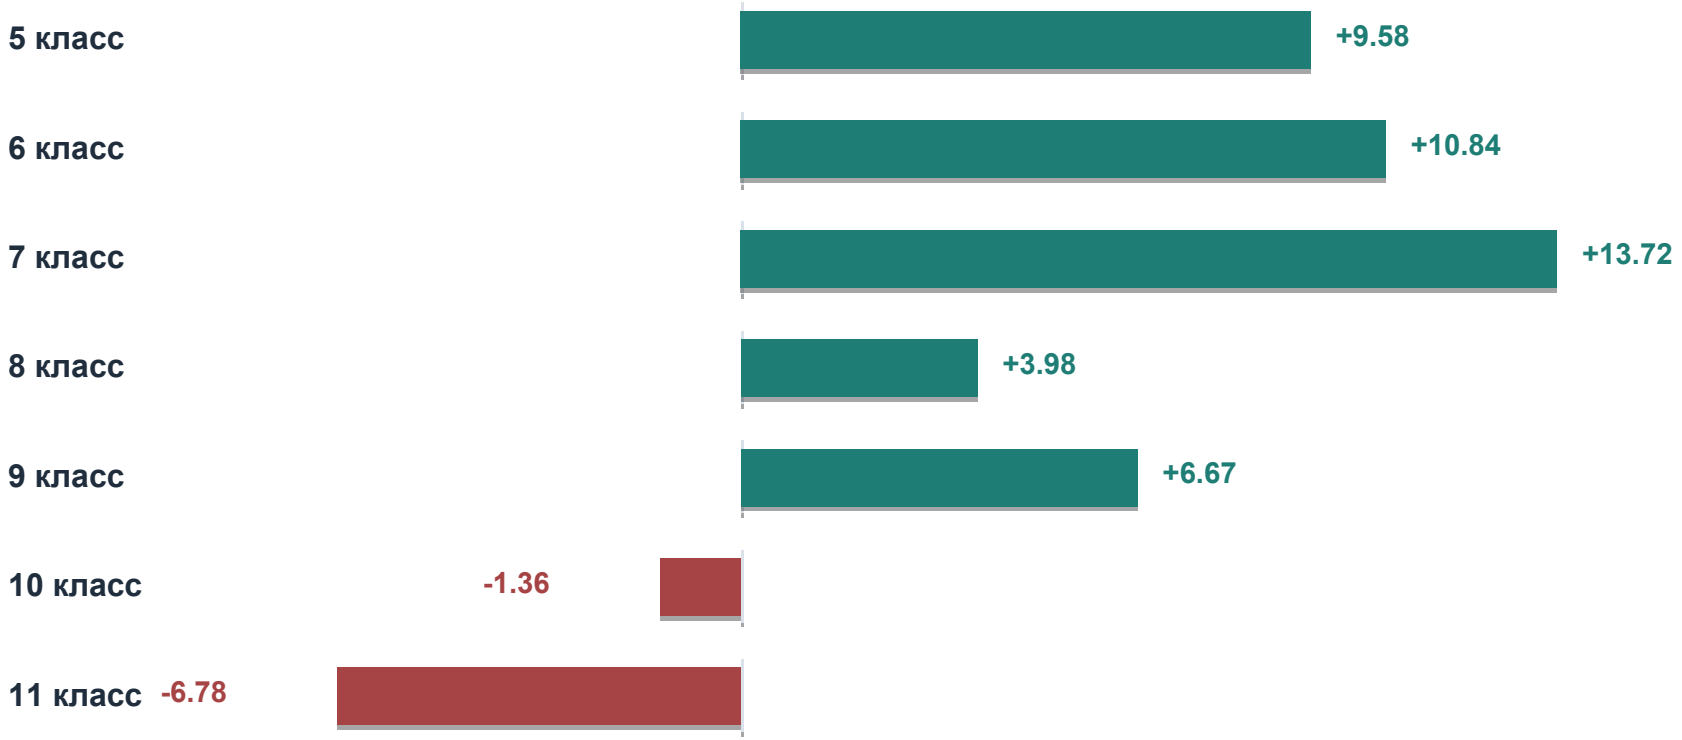
Все три эффекта положительны; скорректированные p-value < 0,05, доверительные интервалы не пересекают ноль.

Проверка устойчивости

Исключение 12 пользователей с >500 событиями практически не изменило величины эффектов.

Сегментация меняет продуктовое решение

Разница Retention D7 между B и A по классам в процентных пунктах



Значимая неоднородность

Взаимодействие «группа × класс» значимо для D7 и D14 ($p < 0{,}001$).

Важная оговорка

Отрицательные оценки для 10–11 классов не доказывают вред в каждом сегменте без отдельной проверки.

Решение: адаптировать механику и перепроверить

Следующие действия для продуктовой команды и ограничения исследования

01 Не запускать на всех

Отложить массовое внедрение текущей версии.

02 Исследовать старшие классы

Проверить сценарии и причины слабых результатов 10-11 классов.

03 Повторить эксперимент

Адаптировать механику и провести подтверждающий A/B-тест.

Ограничения данных

Нет события завершения курса или модуля; оценена лишь доля учеников, завершивших ≥1 ДЗ.

Воронка фиксирует наличие событий, а не строгий порядок.

Что улучшить в измерениях

Добавить course_completed/module_completed, уточнить определение D7/D14 и заранее закрепить основную метрику.

ИТОГ Положительный общий эффект - аргумент в пользу дальнейшей разработки, но не автоматического полного запуска для всех пользователей продукта